



واکنش الگوریتم های خانواده درخت تصمیم در برابر حذف ویژگی های با وزن سبک و سنگین

محمد رحیمی^{۱*} مسعود رحیمی^۲

1- دانشگاه علم و صنعت ایران ، واحد نور Rahimi_m72@noor.iust.ac.ir

2- دانشگاه شیخ بهایی اصفهان m.rahimi@shbu.ac.ir

چکیده

مقدمه: امروزه با توجه به رشد روزافزون داده ها انگیزه برای استفاده و کشف دانش از میان داده های موجود دو چندان شده است. داده کاوی تکنیکی است که به بررسی حجم انبوهی از داده ها می پردازد و با توجه به نظم موجود در میان این داده ها اطلاعات سودمندی به ما می دهد که در اصطلاح کشف دانش صورت گرفته است. با بررسی حجم انبوه داده ها در زمینه پزشکی با استفاده از تکنیک های داده کاوی می توان نتایج بسیار مهمی در خصوص پیش بینی و تشخیص هر چه دقیق تر بیماری ها ، شناسایی عوارض داروها ، تعیین نوع درمان و ... به دست آورد.

با عنایت به این نکته که بیماری های قلبی-عروقی و هیپاتیتی از عامل های مرگ و میر در جهان می باشند [۱] مجموعه داده های مربوط به بیماری های قلبی و عروقی و بیماری های هیپاتیت از انبار داده ای سایت UCI استخراج گردید. هدف از ارائه این مقاله بالا بردن دقت مجموعه ای از الگوریتم های خانواده درخت تصمیم و بررسی تاثیر حذف برخی از ویژگی ها در الگوریتم های کشف قوانین انجمنی است.

کلمات کلیدی: داده کاوی ، دسته بندی ، درخت تصمیم ، قوانین انجمنی

1. مقدمه

امروز در عصری زندگی می کنیم که داده ها هر روز نسبت به قبل رشد قابل توجهی دارند. حجم انبوه داده ها امکان بررسی به وسیله انسان را تقریباً ناممکن کرده است به طوریکه در سال 2012 ، 17.5 میلیون نفر جان خود را بر اثر بیماری های قلبی عروقی از دست داده اند [2] که قطعاً بررسی ویژگی های این بیماران به وسیله انسان تقریباً کار غیرممکنی است. از این رو برای بررسی این حجم از داده ها از تکنیک های داده کاوی برای پیشگویی نتایج و بررسی این ویژگی ها استفاده می کنیم. داده کاوی اولین بار در اواخر دهه 1980 و اوایل دهه 1990 پدیدار گشت و بعد از آن گام های بلندی جهت پیشرفت این شاخه از تکنولوژی برداشته شد و انتظار می رود در این قرن این تکنولوژی رشد بسیار زیادی کند. از جمله مهمترین دلایل استفاده از داده کاوی هزینه پایین آن نسبت به استخدام یک تیم خبره ، در نظر نگرفتن تجربیات گذشته و حجم انبوه داده ها می باشد.

داده کاوی شکل پیشرفته پشتیبانی از تصمیم است و برخلاف ابزارهای پرس و جوی غیرفعال Passive بدون الزام به طرح سوال از طرف کاربر، به تولید الگو، روندها و قواعد برنامه ریزی شده می پردازد. به عبارت دیگر قدرت داده کاوی در این است

* Corresponding author: mohammad rahimi
Email: Rahimi_m72@noor.iust.ac.ir



که می‌تواند الگوهایی را که مورد توجه کاربر قرار نگرفته است، افشا کند و پاسخ‌هایی را برای سؤالاتی که هرگز درخواست نشده بود، تولید نماید.[3]

امروزه داده‌کاوی در حوزه سلامت کاربرد فراوانی دارد. برخی از اقدامات تشخیصی و آزمایشگاهی برای بیماران تهاجمی و هزینه‌بر هستند Thangavel و همکاران از طریق الگوریتم‌های خوشه‌بندی به تحلیل بیماران مبتلا به سرطان گردن رحم پرداختند و نتایج پیش‌گیری‌کننده تری را نسبت به عقاید پزشکی کنونی پیدا کردند. همچنین Gorunescu نشان داد که داده‌کاوی می‌تواند با ادغام CAD (تشخیص با کمک کامپیوتر) و اندوسکوپی اولتراسونوگرافی در شناسایی غیرتهاجمی سرطان به عنوان یک شیوه جدید به کار رود. همچنین داده‌کاوی می‌تواند در تعیین نوع درمان به کار برود. به عنوان مثال در بیمارستان شهید هاشمی نژاد تهران برای تعیین نوعی درمان سنگ حالب از راهکار داده‌کاوی استفاده می‌شود. در این بیمارستان یک الگوریتم درختی وجود دارد که پزشک براساس آن درمانی را که میزان موفقیت بالاتری برای بیمار دارد انتخاب می‌کند. بررسی‌ها نشان داده است که میزان عملکرد این الگوریتم 77 درصد بوده و بسیار بهتر از عملکرد الگوریتم بیمارستان و مدل ذهنی پزشکان می‌باشد. همچنین داده‌کاوی می‌تواند در شناسایی عوارض داروها استفاده شود. به طوریکه اداره دارو و غذای آمریکا با استفاده از تکنیک‌های داده‌کاوی توانستند به کشف دانش درباره عوارض جانبی داروها در پایگاه داده خود بپردازند و با استفاده از الگوریتم MGPS با دقت 67 درصد عوارض جانبی داروها را 5 سال زودتر از شیوه سنتی شناسایی کنند. همچنین داده‌کاوی می‌تواند الگوهای مهم سلامت که درون پرونده‌های پزشکی می‌باشد شناسایی کند. به علاوه عملکرد سیستم‌های داده‌کاوی در کنترل عفونت در مقایسه با سیستم‌های سنتی موفق‌تر عمل کرده است. به طوری که سیستم نظارتی که با تکنیک‌های داده‌کاوی در بیمارستان آلباما ساخته شده بود توانست نتایج قابل توجهی را بدست بیاورد و الگوهایی که ماهانه توسط کارشناسان کنترل عفونت مورد بررسی قرار می‌گرفتند را تهیه کند. علاوه بر این داده‌کاوی می‌تواند در رتبه‌بندی بیمارستان‌ها و بهره‌برداری از خدمات سلامت مورد استفاده قرار بگیرد. در برنامه سلامت آکسفورد داده‌کاوی، به دنبال پاسخ به موضوعات پیچیده می‌باشد که از آن جمله می‌توان به خدمات ارائه شده به بیماران و نحوه مراقبت‌های انجام شده اشاره کرد. همچنین داده‌کاوی می‌تواند شرایط پرخطر را شناسایی و مدیریت کند. به عنوان نمونه تکنیک‌های مدل‌سازی داده‌کاوی می‌تواند بیماری دیابت را مدیریت کند و باعث کاهش هزینه‌ها و ارتقای کیفیت خدمات شوند.[4]

همچنین تکنیک‌های داده‌کاوی می‌تواند به پزشکان کمک کند تا عملکرد آن‌ها نسبت به گذشته از کیفیت بالاتری برخوردار شود. این تکنیک‌ها می‌توانند در پیش‌بینی و تشخیص بیماری‌ها به پزشکان کمک کنند. با توجه به اینکه همه پزشکان در تمام زمینه‌های شغلی خود مهارت ندارند و یا در بعضی موارد نیروهای متخصص کمی وجود دارند از این رو وجود سیستمی که بتواند نوع بیماری و درمان را تشخیص دهد می‌تواند کیفیت عملکرد یک پزشک را بالا ببرد و موجب کاهش هزینه‌ها، افزایش دقت و کارایی شود. همچنین داده‌کاوی می‌تواند اثربخشی معالجات و تکنیک‌های متفاوت درمانی بر روی بیماران مختلف را ارزیابی کند و بازخورد آن‌ها را برگرداند. به عنوان نمونه داده‌کاوی می‌تواند روش‌های مختلف درمان یک بیماری را بر روی بیماران مختلف بررسی کند و میزان اثربخشی هر تکنیک را تعیین نماید و یا معالجات موفق را شناسایی نماید.[4]

داده‌کاوی با بررسی حجم انبوه داده‌ها به نظم و الگوهای موجود در داده‌ها پی می‌برد و آن‌ها را به عنوان دانش جدید ارائه می‌کند. فرآیند کشف دانش به وسیله داده‌کاوی به این صورت است که ابتدا مسئله تفهیم می‌شود، سپس بر روی داده‌ها پیش‌پردازش انجام می‌شود. در پیش‌پردازش، داده‌ها یکپارچه می‌شوند، داده‌های نویزی حذف می‌شوند، مقادیر مفقودشده به وسیله مقادیر مناسب جایگزین می‌شوند. سپس نوبت به پردازش می‌رسد. در این مرحله با استفاده از الگوریتم‌های داده‌کاوی داده‌ها را مورد پردازش قرار می‌دهیم و شروع به تفسیر نتایج بدست آمده می‌کنیم. در آخرین مرحله دانش کشف شده را از نتایج مفید بدست آمده استخراج می‌کنیم.



تکنولوژی داده کاوی به طور کلی به چهار دسته کلاس بندی، خوشه بندی، قواعد مشارکت، رگرسیون تقسیم می شود. طبقه بندی فرآیندی است که داده های جدید در طبقاتی قرار می گیرند که این طبقات در واقع بر اساس داده های قبلی ایجاد شده اند این روش غالباً از الگوریتم های همراه با ناظر استفاده می کند یعنی بخشی از داده ها برای آموزش سیستم تخصیص داده می شوند و کلاس بندی بر اساس آن ها صورت می گیرد. شبکه های عصبی، درخت تصمیم، k - نزدیکترین همسایه، ماشین بردار تصمیم، رگرسیون لجستیک، طبقه بند بیز ساده و ... از نمونه الگوریتم های طبقه بندی می باشند. در خوشه بندی ما داده هایی با ویژگی های نزدیک به هم را درون یک خوشه قرار می دهیم. خوشه بندی روشی بدون ناظر است به طوریکه داده های ورودی هیچ برچسبی برای عضویت ندارند و خوشه بندی بر اساس مشاهدات انجام می شود. در قواعد مشارکت طبقه بندی بر اساس داده های تکراری انجام می شود و در ضمن با شناسایی ارتباطات بین داده ها و ویژگی های آن ها الگو های تکراری مشخص می شود. [5] اما عملکرد رگرسیون مشابه کلاس بندی است با این تفاوت که کلاس هایی را شناسایی می کند که یک مقدار عددی را برگرداند.

2. تعاریف مفاهیم پایه و متغیرهای پروژه

الگوریتم درخت تصمیم یکی از مشهورترین و قدیمی ترین الگوریتم های ساخت مدل دسته بندی است. در این الگوریتم نتایج به صورت یک درخت ارائه می گردند. با توجه به اینکه ویژگی مورد پیش بینی در برگ درخت قرار می گیرد مسیر رسیدن به برگ درخت می تواند به ما اطلاعات مفیدی جهت رسیدن به مجموعه رکوردهای آن ویژگی بدهد. به عبارت دیگر می توانیم درخت تصمیم را با برچسب های موجود بر روی هر یال تا رسیدن به عنصر مورد پیش بینی تفسیر کنیم. **Decision Tree** یک درخت تصمیم گیری می باشد که با یک گره اولیه شروع می شود و پس از آن پیامدهای احتمالی به صورت شاخه هایی از آن منشعب شده و هر کدام از آن پیامدها به گره های دیگری منجر شده که آن ها هم به نوبه ی خود شاخه هایی از احتمالات دیگر را ایجاد می کنند که این ساختار شاخه شاخه سرانجام به نموداری شبیه به یک درخت مدل می شود.

ID3 یکی از الگوریتم های پایه برای ساخت درخت های تصمیم است. این الگوریتم ابتدا ویژگی را انتخاب می کند که بتواند به ما اطلاعات بیشتری بدهد و جستجو را کمتر کند به عنوان نمونه ما می خواهیم یک کتاب تاریخ را در میان یک سری کتاب پیدا کنیم. یک حالت این است که اطلاعات جستجو به همان مقدار "کتاب تاریخ" باشد اما زمانی که می گوئیم "کتاب تاریخ سبز" رنگ داریم و معیار جستجو کتاب تاریخ سبز رنگ قرار می گیرد بنابراین مقدار جستجو نسبت به حالت قبل بسیار محدودتر می شود. در واقع الگوریتم ID3 ویژگی هایی را انتخاب میکند که اطلاعات بیشتری را به ما بدهد.

Apriori: این الگوریتم معروف ترین الگوریتم جستجوی اول سطح شبکه اشیاء جهت تولید مجموعه اشیاء تکراری می باشد. این الگوریتم از یک روش تکراری برای یافتن مجموع اشیاء تکراری استفاده می کند. در این الگوریتم ابتدا مجموعه اشیاء یک عضوی جستجو می شوند که آن ها را با F_1 نشان می دهیم. سپس از F_1 برای یافتن F_2 استفاده می کنیم به عبارتی برای پیدا کردن مجموعه اشیاء دو عضوی از مجموعه های تک عضوی استفاده می کنیم. در نهایت برای یافتن F_{k+1} از F_k استفاده می کنیم. ایده اصلی این الگوریتم این است که اگر مجموعه اشیایی تکراری باشند تمام زیر مجموعه های آن مجموعه اشیاء باید مکرر شوند.

W-InfoGainAttributeEval: این عملگر ارتباط ویژگی را بر پایه بهره اطلاعات محاسبه می کند. اگر نیاز باشد که مجموعه داده ها بر اساس یک ویژگی تقسیم شود این عملگر ارتباط آن ویژگی را با استفاده از بهره اطلاعات در توزیع دسته ها محاسبه می نماید و به ویژگی ها وزن می دهد. این الگوریتم همه مقادیری که یک ویژگی می تواند دریافت کند را با



مقادیر دسته‌های مختلف در نظر می‌گیرد و یک سیگما نیز با استفاده از آن محاسبه می‌نماید در نهایت بیشتر بودن میزان این سیگما نشان دهنده ارتباط بیشتر دسته با یکی از مقادیر ویژگی در مجموعه داده می‌باشد. نتایج در انتها درون یک ماتریس همبستگی ذخیره خواهد شد و قابل استفاده می‌باشد.

W-ChiSquaredAttributeEval: این عملگر ارتباط هر یک از ویژگی‌های مجموعه ورودی را با استفاده از معیار chi-squared یا توجه به ویژگی برچسب محاسبه می‌نماید و بر آن اساس ویژگی‌ها را وزن دهی می‌نماید.

الگوریتم X-Means

الگوریتم خوشه بندی k-means یکی از ساده ترین و البته مشهورترین الگوریتم‌های یادگیری بدون نظارت است که k-means عملاً مجموعه داده به تعداد خوشه‌هایی از پیش تعریف شده تقسیم می‌شوند. ایده اصلی در این الگوریتم تعریف k مرکز برای k خوشه است بهترین انتخاب برای مراکز خوشه‌ها در الگوریتم K-Means قرار دادن آن‌ها قرار دادن آن‌ها در فاصله هر چه بیشتر از یکدیگر است پس از آن هر رکورد در مجموعه داده به نزدیکترین مرکز خوشه تخصیص می‌یابد. در ادامه می‌توان مشکلات این الگوریتم را به صورت ذیل بر شمرد.

- جواب نهایی به انتخاب مراکز اولیه خوشه وابستگی بسیاری دارد.
- روال مشخص برای محاسبه مرکز اولیه خوشه‌ها وجود ندارد
- اگر در تکراری از الگوریتم تعداد اعضای خوشه‌ای صفر شد البته به جز مرکز خوشه راهی برای تغییر و بهبود وضعیت وجود ندارد. در این روش فرض شده است که تعداد خوشه‌ها از ابتدا مشخص است، اما معمولاً در بسیاری از مسائل کاربردی تعداد خوشه‌ها مشخص نیست

یکی از راه حل‌هایی که برای رفع مشکلات انتخاب مراکز ابتدایی خوشه و بدست آوردن مقدار بهینه k در الگوریتم k-means پیشنهاد می‌شود اجرای چندین باره الگوریتم است، که این مسئله ما را به سوی الگوریتم خوشه بندی x-means سوق می‌دهد.

الگوریتم خوشه بندی x-means در سال 2000 به وسیله dan plet و Andrew moor ارائه شد که به طور موثر فضای خوشه‌ها و تعداد خوشه‌ها برای بهینه‌سازی مقادیر جستجو می‌کند و برای اندازه‌گیری این بهینه‌سازی از معیارهای BIC و AIC استفاده می‌کنیم. الگوریتم X-Means ابتدا دو مقدار برای تعیین محدوده K در نظر می‌گیرد. پس از آن مقدار k را برابر با کوچکترین مقدار محدوده قرار می‌دهد. و الگوریتم k-means اجرا می‌شود و با اضافه کردن مقدار k روند به همین‌گونه ادامه می‌یابد تا K به حداکثر مقدار خود برسد و در طول این فرآیند مجموعه مراکز که بهترین امتیاز را بدست آورده‌اند به عنوان خروجی انتخاب می‌شود. مراحل x-means به ترتیب زیر می‌باشد

- 1- بهبود پارامترها
- 2- بهبود ساختار
- 3- توقف الگوریتم اگر $K > K_{max}$ شود و گزارش بهترین امتیاز همراه با مراکز به دست آمده غیر این‌صورت به مرحله یک برو. [13], [14]

3. کارهای انجام شده (پیشینه تحقیق):

مقاله صفدری و همکارانش با موضوع "مقایسه عملکرد درخت تصمیم و شبکه عصبی در پیشگویی ابتلا به آنفارکتوس قلبی" بررسی شد و در این مقاله بهترین مدل ایجاد شده توسط درخت تصمیم C5 ارائه گردید که صحت مدل ایجاد شده با استفاده از الگوریتم درخت تصمیم 93.4 درصد می‌باشد. همچنین در این مقاله متغیرهای فشارخون بالا، چربی خون بالا و سیگار بیشترین وزن را در مقایسه با سایر ویژگی‌های پایگاه داده داشته‌اند. [7]

مقاله محمودی با عنوان "طراحی سیستم پیش بینی بیماری قلبی - عروقی با استفاده از ماشین بردار پشتیبان" مورد بررسی قرار گرفت که در این مقاله پژوهشگر الگوریتمی پیشنهاد می‌دهد که نرخ دسته بندی، نرخ صحت، نوع فراخوانی، و



F-سنجش الگوریتم به ترتیب 85، 83.5، 85.8 و 85 درصد می باشد. که این الگوریتم در مقایسه با معیارهای ارزیابی سایر الگوریتم ها از جمله C4.5، K-NN، Naïve Bayes، RBF Network، نتایج بهتری را ارائه کرده است. [8] مقاله مظاهری با عنوان "پیش بینی روش درمان بیماری قلبی با استفاده از الگوریتم های داده کاوی" بررسی گردید و در این مقاله الگوریتم های درخت تصمیم با عنوان C5.0، CHAID، QUEST، C&R Tree و الگوریتم شبکه عصبی با عنوان Neural Net مورد مقایسه قرار گرفتند. پژوهشگر با ارزیابی معیار صحت الگوریتم های بالا به این نتیجه رسید که درخت تصمیم C&R Tree با مقدار 76.04 نسبت به سایر الگوریتم های درخت تصمیم و الگوریتم شبکه عصبی Neural Net از صحت بالاتری برخوردار است. [9]

مقاله کاظمی با موضوع "پیش بینی بیماری قلبی با استفاده از تکنیک داده کاوی شبکه عصبی" مورد بررسی قرار گرفت. در این مقاله مدل شبکه عصبی با ساختار پرسپترون چند لایه در مرحله اول داده های مدل ساز را با دقت 87.75 کلاس بندی می کند سپس در مرحله بعدی، کلاس بندی بر روی مجموعه داده های آزمون با دقت 83.33 انجام می گیرد. [10] مقاله صباغ گل با موضوع "تشخیص بیماری عروق کرونر قلبی با استفاده از درخت تصمیم C4.5" مورد بررسی قرار گرفت در این مقاله الگوریتم های درخت تصمیم C4.5، CHAID، QUEST، C&RT، بررسی و مورد ارزیابی قرار گرفتند. الگوریتم درختی C4.5 با معیارهای ارزیابی حساسیت، ویژگی، ارزش اخبار مثبت، ارزش اخبار منفی، دقت به ترتیب مقادیرهای 84.1، 72.6، 84.1، 61.8، 80.2 را دارا بود که در مقایسه با سایر الگوریتم ها مقادیر قابل قبولی بودند. همچنین پژوهشگر به بررسی قوانین انجمنی حاصل از این پایگاه داده می پردازد. [11]

مقاله آیت الهی با موضوع "مقایسه عملکرد الگوریتم های داده کاوی در پیش بینی بیماری عروق کرونر" بررسی گردید. در این مقاله الگوریتم های مدل شبکه عصبی مصنوعی و ماشین های بردار مقایسه گردیدند. معیارهای ارزیابی از جمله میانگین درصد خطای مطلق، هاسمر - لمشو، حساسیت و ویژگی در مورد هر دو الگوریتم مورد بررسی قرار گرفت و مشخص گردید الگوریتم ماشین پشتیبان بردار عملکرد بهتری نسبت به مدل شبکه عصبی دارد. [12] این نتایج می تواند باعث تسریع در شناسایی تنگی عروق هر فرد گردد. همچنین روابط و قوانین مهمی جهت پیش بینی این بیماری کشف گردیده است به طوریکه میزان اهمیت هر ویژگی جهت تشخیص تنگی عروق هر فرد شناسایی گردیده است. هدف اصلی ما در این پژوهش بهبود دقت و کاهش زمان اجرای الگوریتم های خانواده درخت تصمیم و همچنین کاهش زمان اجرای الگوریتم Apriori، به وسیله کاهش ابعاد مسئله می باشد به طوریکه دقت هر الگوریتم جهت تشخیص بیماری بررسی می شود.

4. روش پیشنهادی:

مراحل اجرای الگوریتم پیشنهادی به شرح زیر می باشد. تمامی محاسبات با نرم افزار Rapid Miner صورت گرفته است. به منظور افزایش دقت و سرعت اجرای الگوریتم های خانواده درخت تصمیم و افزایش سرعت الگوریتم های خانواده کشف قواعد انجمنی، الگوریتمی به شرح زیر ارائه می شود.

گام اول: در مرحله اول این الگوریتم عملیات پیش پردازش بر روی داده ها انجام می پذیرد که این مرحله خود شامل چند بخش می باشد. که در ادامه توضیح داده خواهد شد.

1- حذف داده های پرت: یکی از مشکلات شایع داده پایین بودن کیفیت آن است. در اینجا با استفاده از الگوریتم خوشه بندی

X-Means داده های پرت و بی کیفیت شناسایی شده و از مجموعه داده ها حذف می گردند.



2- تخمین زدن و جایگزین مقادیر از دست رفته: به دلایلی ممکن است بعضی از مقادیر مربوط به برخی ویژگی‌ها Null باشند که در اینجا لازم است مقادیر Null با استفاده از روش‌های ابتکاری مانند میانگین گیری تخمین زده شوند و جایگزین مقدار Null شوند.

3- گسسته سازی: در عملیات گسسته سازی داده، هدف آن است که نوع ویژگی‌های بازه‌ای و نرخی به نوع اسمی تبدیل شوند با گسسته سازی داده سختی مسئله را کاهش داده و زمان لازم را برای عملکرد موثرتر الگوریتم فراهم می‌شود.

گام دوم: در این مرحله با اجرای الگوریتم وزن دهی بر روی ویژگی‌های مجموعه داده سعی می‌شود که با استفاده از یک مکانیسم مشخص، ارزش (وزن) هر یک از ویژگی‌ها را برای تشخیص دسته مشخص نمود. به عنوان مثال اگر یک مجموعه داده را برای تعیین بیماری دیابت بیماران به یک مدل اعمال کنیم، فاکتوری مانند رنگ چشم بیمار دارای ارزش ناچیزی در برابر فاکتوری مانند قند خون است. با وزن دهی مناسب، این میزان تاثیر را در داده مشخص خواهیم نمود. و همچنین پس از اجرا الگوریتم وزن دهی نرمال سازی وزن‌ها میان مقادیر صفر تا یک صورت می‌پذیرد.

گام سوم: در این مرحله ویژگی‌هایی با وزن یک و ویژگی‌هایی با وزن صفر یا نزدیک به صفر مشخص می‌گردند و از مجموعه داده حذف خواهند شد.

گام چهارم: اجرای الگوریتم‌های درخت خانواده درخت تصمیم و خانواده کشف قواعد انجمنی بر روی مجموعه داده اصلاح شده

گام پنجم: محاسبه معیار ارزیابی الگوریتم‌های دسته بندی و شمارش تعداد قوانین وابسته به ویژگی برچسب در الگوریتم‌های کشف قوانین انجمنی معیارهای ارزیابی:

در این بخش معیارهای ارزیابی الگوریتم‌های دسته بندی و کشف قوانین انجمنی به تفصیل مورد بررسی قرار می‌گیرند.

معیارهای ارزیابی الگوریتم‌های دسته بندی:

در این بخش انواع معیارهای ارزیابی الگوریتم‌های دسته بندی را، مستقل از نوع روش دسته بندی، مورد بررسی قرار می‌گیرد. در ادامه با توجه به آنکه دسته بندی از جمله روش‌های داده کاوی با ناظر محسوب می‌شود، به بحث پیرامون انواع مختلف روش‌های ارزیابی الگوریتم‌های دسته بندی پرداخته خواهد شد.

قبل از آنکه به بررسی انواع مهم معیارهای دسته بندی پرداخته شود، لازم است که مفهوم ماتریس درهم ریختگی تشریح شود. این ماتریس چگونگی عملکرد الگوریتم دسته بندی را با توجه به مجموعه داده‌های ورودی به تفکیک انواع دسته‌های مسئله نشان می‌دهد. در این ماتریس مفاهیم TP ، FN ، FP ، TN به شرح زیر می‌باشد.

TN : این مقدار بیانگر تعداد رکوردهایی است که دسته واقعی آن‌ها منفی بوده و الگوریتم دسته بندی نیز دسته آن‌ها را به درستی منفی تشخیص داده است.

FP : این مقدار بیانگر تعداد رکوردهایی است که دسته واقعی آن‌ها منفی بوده و الگوریتم دسته بندی آن‌ها را به اشتباه مثبت تشخیص داده است.

FN : این مقدار بیانگر تعداد رکوردهای است که دسته واقعی آن‌ها مثبت بوده و الگوریتم دسته بندی آن‌ها را به اشتباه منفی تشخیص داده است.

TP : این مقدار بیانگر تعداد رکوردهای است که دسته واقعی آن‌ها مثبت بوده و الگوریتم دسته بندی نیز دسته آن‌ها را به درستی مثبت تشخیص داده است.



جدول ۱ - ماتریس درهم ریختگی برای یک مسئله دسته بندی دو دسته ای

دسته منفی	دسته مثبت	رکوردهای تخمینی
		رکوردهای واقعی
TN	FP	دسته منفی
FN	TP	دسته مثبت

اکنون به تشریح انواع مهم معیارهای ارزیابی الگوریتم های دسته بندی با توجه به ماتریس درهم ریختگی پرداخته می شود. مهمترین معیارها برای تعیین کارایی یک الگوریتم دسته بندی به شرح زیر می باشد.

1- **دقت با نرخ دسته بندی (classification accuracy):** این معیار دقت کل یک دسته بند محاسبه می نماید. این معیار نشان دهنده این حقیقت است که دسته بند طراحی شده چند درصد از کل مجموعه رکوردهای آزمایشی به درستی دسته بندی کرده است. دقت دسته بندی بر اساس مفاهیم مطرح شده در ماتریس درهم ریختگی با توجه به رابطه 1 قابل محاسبه است.

$$Ca = (TN + TP) / (TN + FN + TP + FT) \quad (1)$$

دو مقدار TP و TN مهمترین مقادیری هستند که در یک مسئله دو دسته ای باید بیشینه شوند. توجه داشته باشید که معیار دقت دسته بندی مشهورترین و عمومی ترین معیار محاسبه کارایی الگوریتم های دسته بندی است.

2- **معیار خطا:** این معیار دسته بندی دقیقاً برعکس معیار دقت دسته بندی است. کمترین مقدار آن برابر صفر (بهترین کارایی) و بیشترین مقدار آن برابر یک (ضعیف ترین کارایی) است. رابطه شماره 2 نحوه محاسبه این معیار را نشان می دهد.

$$ER = (FN + FP) / (TN + FN + TP + FT) \quad (2)$$

توجه داشته باشید که در روابط شماره 1 و 2 در دسته بندی که برچسب برخی از رکوردها نامشخص تعیین می نمایند، به این شکل تغییر می کنند که مخرج کسرها برابر با کل رکوردهای مورد بررسی قرار داده می شود. توجه داشته باشید چنانچه در یک کاربرد خاص، ارزش دسته ای در مقایسه با دسته دیگر متفاوت باشد، در آن صورت پیش بینی درست یا غلط برچسب رکوردهای آن دسته نفع و یا ضرر متفاوتی را در قیاس با رکوردهای سایر دسته ها به همراه خواهد داشت. به همین دلیل معیارها و روش هایی جهت حل این مشکل در اینگونه مسائل که مسائل با دسته های نامتعادل نامیده می شوند وجود دارد که در ادامه به تشریح آن ها پرداخته خواهد شد.

3- **معیار Recall^x:** این معیار دقت دسته بندی دسته X را با توجه به کل رکوردها با برچسب X نشان می دهد و رابطه شماره 3 و 4 معرف این معیار است.

$$Recall^- = TN / (FP + TN) \quad (3)$$

$$Recall^+ = TP / (FN + TP) \quad (4)$$

4- **معیار Precision^x:** این معیار دقت دسته بندی دسته X را با توجه به کل مواردی نشان می دهد که برچسب X برای رکوردهای مورد بررسی توسط دسته بند پیشنهاد شده است و رابطه شماره 5 و 6 معرف این معیار است.

$$Precision^- = TN / (TN + FN) \quad (5)$$

$$Precision^+ = TP / (TP + FP) \quad (6)$$



توجه کنید که معیار $Precision^x$ کارایی دسته بند را با توجه به تعداد رخداد بسته X نشان می دهد حال آنکه معیار $Precision^x$ اساساً مبتنی بر دقت پیش بینی دسته بند است و مبین آن است که به چه میزان می توان به خروجی دسته بند اعتماد کرد. نکته مهمی دیگری که باید در نظر گرفته شود آن است که در دسته بندهایی که برچسب برخی از رکوردها نامشخص تعیین می شود ، باید مخرج روابط مربوط به محاسبه $Recall^x$ را برابر با کل تعداد رکوردهایی با برچسب X در نظر گرفت.

5- معیار $F-Measure^x$: این معیار از ترکیب معیارهای $Precision^x$ و $Recall^x$ به وجود آمده است و در مواردی مورد استفاده قرار می گیرد که نتوان اهمیت ویژه ای را برای هر یک از دو معیار $Precision^x$ و $Recall^x$ نسبت به یکدیگر قائل شد و رابطه شماره 7 و 8 معرف این معیار است.

$$F-Measure^- = (2 Recall^- * Precision^-) / (Recall^- + Precision^-) \quad (7)$$

$$F-Measure^+ = (2 Recall^+ * Precision^+) / (Recall^+ + Precision^+) \quad (8)$$

معیارهای ارزیابی کشف قوانین انجمنی:

در این بخش به معرفی انواع معیارهای مهم و پرکاربرد جهت ارزیابی قوانین انجمنی پرداخته خواهد شد. برای شروع فرض کنید که قانونی به نام R داریم که این قانون به شکل $A \rightarrow B$ است که در آن A و B زیر مجموعه ای از اشیا هستند در ادامه به تشریح چند معیار پر کاربرد پرداخته می شود.

6- معیار **Support**: از نسبت تعداد رکوردهایی که در آن اشیا A و B هر دو حضور دارند به کل تعداد رکوردها معیار مهمی با نام **Support** بدست می آید. این مقدار عددی بین صفر و یک می باشد که هر چه این میزان بیشتر باشد نشان دهنده این است که این دو شی بیشتر با هم در ارتباط هستند.

این معیار به همراه معیار **Confidence** که در ادامه معرفی می شود جز مهمترین معیارهایی هستند که در مقالات مختلف برای مقایسه قوانین بدست آمده توسط الگوریتم های کشف قوانین انجمنی استفاده می شوند. استفاده از معیار **support** به این علت اهمیت دارد که کاربر می تواند با مشخص کردن یک آستانه برای این معیار تنها قوانینی را بدست بیاورد که **Support** آن ها از این آستانه بیشتر باشد. این کار سبب می شود که بتوان از بسیاری از فضای وسیع جستجو صرف نظر کرد و به این ترتیب زمان لازم برای پیدا کردن قوانین انجمنی را کمینه نمود.

استفاده از مقدار آستانه این ضعف را دارد که ممکن است قوانینی وجود داشته باشند که **Support** آن ها از میزان آستانه کمتر باشد ولی قوانین با ارزشی باشد. پس نتیجه می گیریم که استفاده از این معیار به تنهایی برای مشخص کردن قوانین جذب کافی نخواهد بود.

7- معیار **confidence**: این معیار از تقسیم تعداد رکوردهایی که در آن ها A و B با هم تکرار شده اند بر تعداد تراکنش هایی که در آن شی A وجود دارد ، بدست می آید. رابطه شماره 9 نشان دهنده فرمول محاسبه **Confidence** است که نتیجه آن عددی بین صفر و یک است که هر چه این میزان بیشتر باشد بر کیفیت قانون افزوده خواهد شد. برای مثال قانونی با اطمینان 98 درصد نشان می دهد که در 98 درصد حالات اگر سمت چپ قانون درست باشد سمت راست قانون نیز درست خواهد بود.

$$Conf(A \rightarrow B) = Sup(A \cup B) / Sup(A) \quad (9)$$



6- ارزیابی نتایج:

در بخش بعدی به بررسی و محاسبه و مقایسه پارامترهای ذکر شده در حالت های مختلف می پردازیم.
به منظور ارزیابی روش پیشنهادی پایگاه داده های Heart-c و Hepatitis از انبار داده ای UCI استخراج گردید و روش پیشنهادی به وسیله ابزار Rapid Miner بر روی پایگاه داده Heart-c با 14 ویژگی و 303 رکورد و پایگاه داده Hepatitis با 20 ویژگی و 155 رکورد اجرا گردید. و نتایج به همراه معرفی دقیق مجموعه داده ها در ادامه به شرح زیر ارائه شده است.
ارزیابی نتایج روش پیشنهادی بر روی مجموعه داده Heart-c
پایگاه داده Heart-c اطلاعات مربوط به بیماری های قلبی را در قالب 13 ویژگی و 303 رکورد ارائه می دهد که توضیح دقیق ویژگی های آن در جدول 2 ارائه شده است.

جدول ۲- توصیف ویژگی های مجموعه داده اول

ویژگی	نام توضیحات	مقادیر
Age	سن بیمار	29-77
Sex	جنسیت بیمار	Male , Female
Cp	درد قفسه سینه	asympt (بدو علامت) و non_anginal (درد بدون آنژینال) (آنژین حاد) atyp_angina (آنژین معمولی) typ_angina
Trestbps	فشار خون در زمان استراحت	94-200
Chol	کلسترول	126-564
Fbs	قند خون ناشتا (بالای 120 گرم قند خون دارد)	(قند خون ندارد) False ، (قند خون دارد) True
Restecg	نتایج نوار قلب در حال استراحت	Normal (نرمال) ، left_vent_hyper (موج افزایشی مقطعی) st_t_wave_abnormality (موج غیر قلبی)
Thalach	ماکزیمم ضربان قلب	71-202
Exang	آنژین ناشی از ورزش	No و Yes
Oldpeak	افسردگی ایجاد شده St موقع تست ورزش	0 - 6.2
Slope	در زمان حداکثر ورزش St شیب قطعه	Down و Flat و up
Ca	تعداد رگ هایی که در فلوروسکوپی مشاهده گردید	0-3
Thal	اسکن تالیوم	fixed_defect ، normal ، reversable_defect ، Blonk
Num	تشخیص بیماری قلبی به وسیله تنگی عروق	(باریکی قطر) 1_50 > ، (باریکی قطر) 50 <

پارامترهای پایگاه داده دوم: پایگاه داده دوم متشکل از بیست ویژگی بیماری هپاتیت است که این پایگاه داده نیز از انبار داده ای سایت UCI استخراج شده است که در جدول 3 به تشریح هر ویژگی پرداخت شده است

1-6- گام های اجرای الگوریتم پیشنهادی بر روی الگوریتم های خانواده درخت تصمیم مجموعه داده 1:

گام اول: پیش پردازش و آماده سازی:

- در این مرحله عملیات پیش پردازش و آماده سازی بر روی داده ها که شامل موارد زیر است انجام می شود
- 1- با اجرای الگوریتم خوشه بندی x-means تعداد هشت رکورد از این مجموعه داده به عنوان داده پرت شناسایی و حذف شد.
- 2- در مرحله دوم با اجرای تابع Replace Missing Value مقادیر از دست رفته با میانگین کل جایگزین شد.
- 3- در این مرحله عملیات گسسته سازی بر روی ویژگی های Age ، Chol ، oldpeak ، thalach و trestbps انجام و به چهار بازه تقسیم شد.



جدول ۳- توصیف ویژگی های مجموعه داده دوم

ویژگی	نام توضیحات	مقادیر
AGE	سن بیمار	7-78
SEX	جنسیت بیمار	Male و Female
STEROID		No و Yes
ANTIVIRALS		Yes و No
FATIGUE		Yes و No
MALAISE		Yes و No
ANOREXIA		Yes و No
LIVER_BIG		Yes و No
LIVER_FRIM		Yes و No
SPLEEN_PALPABLE		Yes و No
SPIDERS		Yes و No
ASCITES		Yes و No
VARICES		Yes و No
HISTOLOGY		Yes و No
BILIRUBIN		[0.3 - 8]
ALK_PHOSP		[26-295]
SGOT		[14-648]
ALBUMIN		[2.1-6.4]
PROTIME		[0-100]
Class		LIVE و DIE

در گام دوم الگوریتم های وزن دهی Weight by information Gain و W-ChiSquaredAttributeEval را به همراه نرمال سازی بر روی ویژگی های این مجموعه داده به منظور مشخص نمودن ارزش هر یک از ویژگی ها برای تشخیص دسته اجرا کرده و نتایج وزن بندی در جدول شماره 4 ارائه شده است.

همانطور که در جدول شماره 4 مشاهده می شود ویژگی Thal بالاترین وزن و ویژگی fbs پایین ترین وزن را در تشخیص دسته دارد.

در گام سوم الگوریتم های Decision Tree، ID3، CHID، Random Forest بدون حذف هیچ ویژگی بر روی این مجموعه اجرا کرده و نتایج حاصل از آن در ستون سوم جدول شماره 5 ارائه شده است.

در گام چهارم ویژگی thal را از این مجموعه داده حذف نموده و مجددا همان الگوریتم های گام دوم را اجرا کرده و نتایج آن در ستون چهارم جدول شماره 5 ارائه شده است.

در گام پنجم ویژگی fbs را از این مجموعه حذف نموده و مجددا همان الگوریتم های گام دوم را اجرا نموده و نتایج آن در ستون پنجم جدول شماره 5 ارائه شده است.



جدول ۴- وزن ویژگی های مجموعه داده اول

W-ChiSquaredAttributeEval		Weight by information Gain	
Attribute	Weight	Attribute	Weight
fbs	0	fbs	0
chol	0.061	chol	0.062
trestbps	0.069	trestbps	0.067
restecg	0.116	restecg	0.111
sex	0.280	age	0.278
age	0.283	sex	0.276
oldpeak	0.521	oldpeak	0.525
slope	0.560	slope	0.551
thalach	0.601	thalach	0.617
exang	0.682	exang	0.672
ca	0.877	ca	0.878
cp	0.956	cp	0.968
thal	1	thal	1

در گام ششم ویژگی **thal** و **fbs** را از این مجموعه حذف نموده و مجدداً الگوریتم های گام دوم را اجرا نموده و نتایج آن در ستون ششم جدول شماره 5 قابل مشاهده است.

2-6- گام های اجرای روش پیشنهادی بر روی الگوریتم Apriori مجموعه داده 1:

- گام اول: در این مرحله عملیات پیش پردازش و آماده سازی بر روی داده ها که شامل موارد زیر است انجام می شود
- 1- با اجرای الگوریتم خوشه بندی x-means تعداد هشت رکورد از این مجموعه داده به عنوان داده پرت شناسایی و حذف شد.
 - 2- در مرحله دوم با اجرای تابع RipLace Missing Value مقادیر از دست رفته با میانگین کل جایگزین شد.
 - 3- در این مرحله عملیات گسسته سازی بر روی ویژگی های **Age** ، **Chol** ، **oldpeak** ، **thalach** و **trestbps** انجام و به چهار بازه تقسیم شد.

در گام دوم الگوریتم های وزن دهی **Weight by information Gain** و **W-ChiSquaredAttributeEval** را به همراه نرمال سازی بر روی ویژگی های این مجموعه داده به منظور مشخص نمودن ارزش هر یک از ویژگی ها برای تشخیص دسته اجرا کرده و نتایج وزن بندی در جدول شماره 4 ارائه شده است.

همانطور که در جدول شماره 4 مشاهده می شود ویژگی های **fbs** ، **chol** و **trestbps** پایین ترین وزن را در تشخیص دسته دارند.

در گام سوم الگوریتم **Apriori** را بدون حذف هیچ ویژگی بر روی این مجموعه اجرا کرده و نتایج حاصل از آن را در ستون سوم جدول شماره 6 ارائه شده است.

در گام چهارم ویژگی **fbs** را از این مجموعه داده حذف نموده و مجدداً الگوریتم **Apriori** را اجرا کرده و نتایج آن در ستون چهارم جدول شماره 6 ارائه شده است.

در گام پنجم ویژگی های **fbs** و **chol** را از این مجموعه داده حذف نموده و مجدداً الگوریتم **Apriori** را اجرا کرده و نتایج آن در ستون پنجم جدول شماره 6 ارائه شده است.



جدول ۵- عملیات پردازش بر روی پایگاه داده اول

	حذف Thal , Fbs	حذف Fbs	حذف Thal	تمام ویژگی ها	معیارهای ارزیابی الگوریتم به روش طبقه بندی
Decision Tree	94.55	97.58	96.36	97.58	Class Recall ⁻
	84.78	78.99	84.06	78.99	Class Recall ⁺
	88.14	84.74	87.85	84.74	Class Precision ⁻
	92.86	96.46	95.08	96.46	Class precision ⁺
	91.23	90.70	91.90	90.70	S-Measure ⁻
	88.63	86.85	89.23	86.85	S-Measure ⁺
	90.10	89.11	90.76	89.11	Accuracy
ID3	95.76	96.97	96.36	97.58	Class Recall ⁻
	95.65	93.48	94.93	92.75	Class Recall ⁺
	96.34	94.67	95.78	94.15	Class Precision ⁻
	94.96	96.27	95.62	96.97	Class precision ⁺
	96.04	95.80	96.06	95.83	S-Measure ⁻
	95.30	94.85	95.27	94.81	S-Measure ⁺
	95.71	95.38	95.71	95.38	Accuracy
CHAID	95.15	95.76	94.55	95.76	Class Recall ⁻
	82.61	78.26	83.33	78.26	Class Recall ⁺
	86.74	84.04	87.15	84.04	Class Precision ⁻
	93.44	93.91	92.74	93.91	Class precision ⁺
	90.75	89.51	90.69	89.51	S-Measure ⁻
	87.69	85.37	87.78	85.37	S-Measure ⁺
	89.44	87.97	89.44	87.79	Accuracy
Random Forest	100	100	100	100	Class Recall ⁻
	99.28	99.28	99.28	98.55	Class Recall ⁺
	99.40	99.40	99.40	98.80	Class Precision ⁻
	100	100	100	100	Class precision ⁺
	99.69	99.69	99.69	99.39	S-Measure ⁻
	99.63	99.63	99.63	99.26	S-Measure ⁺
	99.67	99.67	99.67	99.34	Accuracy



در گام ششم ویژگی های fbs ، chol و trestbps را از این مجموعه داده حذف نموده و مجدداً الگوریتم Apriori را اجرا کرده و نتایج آن در ستون ششم جدول شماره 6 ارائه شده است.
در گام آخر ویژگی های fbs ، chol ، trestbps و restecg را از این مجموعه داده حذف نموده و مجدداً الگوریتم Apriori را اجرا کرده و نتایج آن در ستون هفتم جدول شماره 6 ارائه شده است.
جدول ۶- عملیات پردازش بر روی پایگاه داده اول

Apriori	بدون حذف ویژگی	fbs	Chol,fbs	Chol,trestbps , fbs	Chol,trestbps , restecg,fbs
Average Confidence	0.8752	0.8752	0.8752	0.8752	0.878
number of rules	17	17	17	17	15

3-6- گام های اجرای الگوریتم پیشنهادی بر روی الگوریتم های خانواده درخت تصمیم مجموعه داده 2:

گام اول: پیش پردازش و آماده سازی:

- گام اول: در این مرحله عملیات پیش پردازش و آماده سازی بر روی داده ها که شامل موارد زیر است انجام می شود
- 1- با اجرای الگوریتم خوشه بندی x-means تعداد 5 رکورد از این مجموعه داده به عنوان داده پرت شناسایی و حذف شد.
 - 2- در مرحله دوم با اجرای تابع Riplace Missing Value مقادیر از دست رفته با میانگین کل جایگزین شد.
 - 3- در این مرحله عملیات گسسته سازی بر روی ویژگی های AGE ، ALBUMIN ، ALK_PHOSPHATE ، BILIRUBIN ، SGOT انجام و به چهار بازه تقسیم شدند.

در گام دوم الگوریتم های وزن دهی Weight by information Gain و W-ChiSquaredAttributeEval را به همراه نرمال سازی بر روی ویژگی های این مجموعه داده به منظور مشخص نمودن ارزش هر یک از ویژگی ها برای تشخیص دسته اجرا کرده و نتایج وزن بندی در جدول شماره 7 به شرح زیر ارائه شده است.
همانطور که در جدول شماره 7 مشاهده می شود ویژگی ASCTIES بالاترین وزن و ویژگی LIVER_FRIM پایین ترین وزن را در تشخیص دسته دارد.

در گام سوم ، الگوریتم های Decision Tree ، ID3 ، CHID ، Random Forest بدون حذف هیچ ویژگی بر روی این مجموعه اجرا کرده و نتایج حاصل از آن در ستون سوم جدول شماره 8 ارائه شده است.
در گام سوم ویژگی ASCTIES را از این مجموعه حذف نموده و مجدداً همان الگوریتم های گام دوم را اجرا کرده و نتایج آن در ستون چهارم جدول شماره 8 ارائه شده است.
در گام چهارم ویژگی LIVER_FRIM را از این مجموعه حذف نموده و مجدداً همان الگوریتم های گام دوم را اجرا نموده و نتایج آن در ستون پنجم جدول شماره 8 ارائه شده است.
در گام ششم ویژگی ASCTIES و LIVER_FRIM را از این مجموعه حذف نموده و مجدداً الگوریتم های گام دوم را اجرا نموده و نتایج آن در ستون ششم جدول شماره 8 قابل مشاهده است.



جدول ۷- وزن ویژگی های پایگاه داده دوم

W-ChiSquaredAttributeEval		Weight by information Gain	
Attribute	Weight	Attribute	Weight
LIVER_FIRM	0.0	LIVER_FIRM	0.0
SGOT	0.000	SGOT	0.000
LIVER_BIG	0.038	LIVER_BIG	0.053
ANTIVIRALS	0.075	ANOREXIA	0.092
ANOREXIA	0.079	STEROID	0.106
STEROID	0.084	ANTIVIRALS	0.112
SEX	0.134	ALK_PHOSPHATE	0.208
ALK_PHOSPHATE	0.166	SPLEEN_PALPABLE	0.274
SPLEEN_PALPABLE	0.248	SEX	0.285
AGE	0.280	AGE	0.421
FATIGUE	0.424	VARICES	0.599
HISTOLOGY	0.517	MALAISE	0.644
MALAISE	0.522	FATIGUE	0.651
VARICES	0.595	HISTOLOGY	0.665
ALBUMIN	0.625	BILIRUBIN	0.792
SPIDERS	0.687	SPIDERS	0.813
BILIRUBIN	0.764	ALBUMIN	0.896
PROTIME	0.818	PROTIME	0.921
ASCITES	1.0	ASCITES	1

4-6- گام های اجرای روش پیشنهادی بر روی الگوریتم **Apriori** مجموعه داده دوم:

- گام اول: در این مرحله عملیات پیش پردازش و آماده سازی بر روی داده ها که شامل موارد زیر است انجام می شود
- 1- با اجرای الگوریتم خوشه بندی x-means تعداد هشت رکورد از این مجموعه داده به عنوان داده پرت شناسایی و حذف شد.
 - 2- در مرحله دوم با اجرای تابع Riplace Missing Value مقادیر از دست رفته با میانگین کل جایگزین شد.
 - 3- در این مرحله عملیات گسسته سازی بر روی ویژگی های AGE، ALBUMIN، ALK_PHOSPHATE، BILIRUBIN، SGOT انجام و به چهار بازه تقسیم شدند.
- در گام دوم الگوریتم های وزن دهی Weight by information Gain و W-ChiSquaredAttributeEval را به همراه نرمال سازی بر روی ویژگی های این مجموعه داده به منظور مشخص نمودن ارزش هر یک از ویژگی ها برای تشخیص دسته اجرا کرده و نتایج وزن بندی در جدول شماره 7 ارائه شده است.
- همانطور که در جدول شماره 7 مشاهده می شود ویژگی های LIVER_FIRM و SGOT پایین ترین وزن را در تشخیص دسته دارند.
- در گام سوم الگوریتم **Apriori** را بدون حذف هیچ ویژگی بر روی این مجموعه اجرا کرده و نتایج حاصل از آن را در ستون سوم جدول شماره 9 ارائه شده است.
- در گام چهارم ویژگی SGOT را از این مجموعه داده حذف نموده و مجدداً الگوریتم **Apriori** را اجرا کرده و نتایج آن در ستون چهارم جدول شماره 9 ارائه شده است.



جدول ۸- عملیات پردازش بر روی پایگاه داده دوم

	حذف ASCITES LIVER_FIRM	حذف LIVER_FIRM	حذف ASCITES	تمام ویژگی ها	معیارهای ارزیابی الگوریتم به روش طبقه بندی
Decision Tree	98.37	94.31	99.19	94.31	Class Recall+
	75.00	78.12	65.62	78.12	Class Recall-
	93.80	94.31	91.73	94.31	Class Precision+
	92.31	78.12	95.45	78.12	Class precision-
	96.03066	94.31	95.31425	94.31	S-Measure+
	82.75955	78.12	77.77276	78.12	S-Measure-
	93.55	90.97	92.26	90.97	Accuracy
ID3	99.19	99.19	100	97.56	Class Recall+
	100	93.75	93.75	93.75	Class Recall-
	100	98.39	98.40	98.36	Class Precision+
	96.97	96.77	100	90.91	Class precision-
	99.59	98.78	99.19	97.95	S-Measure+
	98.46	95.23	96.77	92.30	S-Measure-
	99.35	98.6	98.71	96.77	Accuracy
CHAID	94.31	93.50	94.31	91.06	Class Recall+
	84.38	90.62	84.38	84.38	Class Recall-
	95.87	97.46	95.87	95.73	Class Precision+
	79.41	78.38	79.41	71.05	Class precision-
	95.08	95.43	95.08	93.33	S-Measure+
	81.81	84.05	81.81	77.14	S-Measure-
	92.26	92.90	92.26	89.68	Accuracy
Random Forest	100	100	100	100	Class Recall+
	96.88	100	96.88	96.88	Class Recall-
	99.19	100	99.19	99.19	Class Precision+
	100	100	100	100	Class precision-
	99.59	100	99.59	99.59	S-Measure+
	98.41	100	98.41	98.41	S-Measure-
	99.35	100	99.35	99.35	Accuracy



در گام پنجم ویژگی‌های SGOT و LIVER_FRIM را از این مجموعه داده حذف نموده و مجدداً الگوریتم Apriori را اجرا کرده و نتایج آن در ستون پنجم شماره ۹ ارائه شده است.

جدول ۹- عملیات پردازش بر روی پایگاه داده اول

Apriori	بدون حذف ویژگی	حذف SGOT	حذف SGOT LIVER_FIRM
Average Confidence	0.8385	0.8385	0.9018
number of rules	14	14	11

۷- ارزیابی نتایج:

در ابتدا نتایج حاصل از اجرای الگوریتم پیشنهادی که شامل الگوریتم‌های خانواده درخت تصمیم است بر روی مجموعه داده‌های Heart-c و Hepatitis بررسی می‌شود. با توجه به مشاهده روند رو به رشد معیارهای accuracy، recall و precision از ستون‌های سه‌الی شش هر دو مجموعه داده نتایجی به شرح زیر استخراج می‌شود.

- ۱- با حذف ویژگی‌هایی با وزن یک یا نزدیک به یک از هر دو مجموعه داده دقت الگوریتم‌های خانواده درخت تصمیم در تشخیص دسته بالاتر می‌رود.
 - ۲- با حذف ویژگی‌هایی با وزن صفر یا نزدیک به صفر از هر دو مجموعه داده دقت الگوریتم‌های خانواده درخت تصمیم در تشخیص دسته دچار کاهش نمی‌شود و بعضاً افزایشی هم هست.
 - ۳- با حذف ویژگی‌هایی با وزن یک یا نزدیک به یک و صفر یا نزدیک به صفر از هر دو مجموعه داده دقت الگوریتم‌های خانواده درخت تصمیم در تشخیص دسته بالاتر می‌رود.
- با توجه به بهبود معیارهای ارزیابی خانواده الگوریتم درخت تصمیم که در موارد یک، دو و سه مشاهده شد می‌توان نتیجه‌گیری کلی به شرح زیر بدست آورد:

- همانطور که مشاهده شد با حذف ویژگی‌های با وزن یک یا نزدیک به یک معیار accuracy افزایش یافت که این نشان دهنده این است که درخت تصمیم در مرحله اول، ویژگی با وزن یک یا نزدیک به یک را به عنوان ریشه درخت تصمیم انتخاب می‌کند که این انتخاب منجر به کاهش دقت معیار ذکر شده گردیده است و در این روش پیشنهادی با شناسایی این ویژگی و حذف آن از مجموعه داده می‌توان درخت تصمیم را مجبور به انتخاب ویژگی دیگری به عنوان ریشه کرد که این امر همانطور که مشاهده شد منجر به افزایش سه معیار accuracy شده است و همچنین با توجه به اینکه یک یا چند ویژگی از مجموعه داده حذف گردیده است منتج به کاهش ابعاد مسئله می‌شود که به نوبه خود باعث کاهش زمان اجرای الگوریتم می‌شود.

در ادامه نتایج حاصل از اجرای الگوریتم پیشنهادی که شامل الگوریتم Apriori است بر روی مجموعه داده‌های Heart-c و Hepatitis بررسی می‌شود. با توجه به مشاهده میانگین confidence و تعداد قوانینی که شامل برچسب دسته هستند نتایجی به شرح زیر استخراج می‌شود.

- ۱- با حذف یک یا چند ویژگی که وزن آن‌ها برای تشخیص دسته صفر یا نزدیک به صفر است تعداد قوانین شامل برچسب دسته کاهش پیدا نکرد.
- ۲- با حذف یک یا چند ویژگی که وزن آن‌ها برای تشخیص دسته صفر یا نزدیک به صفر است میانگین support قوانین که شامل برچسب دسته هستند کاهش پیدا نکرد.



3- با حذف یک یا چند ویژگی که وزن آن‌ها برای تشخیص دسته صفر یا نزدیک به صفر است میانگین confidence قوانین که شامل برجسب دسته هستند کاهش پیدا نکرد.

با توجه به مشاهده معیارهای ارزیابی الگوریتم Apriori می‌توان نتیجه‌گیری کلی به شرح زیر ارائه کرد: همانطور که مشاهده شد با حذف ویژگی‌هایی با وزن صفر یا نزدیک به صفر معیارهای ارزیابی الگوریتم Apriori کاهش پیدا نکرد و همچنین با توجه به حذف تعدادی از ویژگی‌ها کاهش ابعاد مسئله مشاهده می‌شود. که این موضوع منجر به کاهش زمان اجرای الگوریتم می‌شود.

8- بحث و نتیجه‌گیری

در این مقاله روشی ارائه شد که با شناسایی برخی از ویژگی‌های مجموعه داده و حذف آن‌ها منجر به افزایش معیارهای ارزیابی الگوریتم‌های خانواده درخت تصمیم و همچنین باعث کاهش زمان اجرای آن‌ها شد و در ادامه با اجرای روش پیشنهادی بر روی الگوریتم Apriori و با حذف برخی از ویژگی‌ها معیارهای ارزیابی این الگوریتم مانند support و confidence ثابت ماند و با توجه به حذف برخی از ویژگی‌ها شاهد کاهش ابعاد مسئله بودیم که این امر منجر به کاهش زمان اجرای این الگوریتم شد. پیشنهاد می‌شود که به منظور تکمیل این مقاله روش پیشنهادی بهبود داده شود و بر روی سایر الگوریتم‌های دسته‌بندی و کشف قوانین انجمنی بررسی و نتایج آن ارائه شود.

[1] World Health Organization, Cardiovascular diseases (CVDs)

[2] سلامت نیوز ، خبر: 226063 ،

[3] حمید قدسی، اعظم السادات حسینی ، فرخنده اسدی ، مریم جهانبخش "داده کاوی و کاربرد آن در سلامت" مدیریت اطلاعات سلامت 1391

[4] محمد رحیمی "مروری بر تکنیک‌های داده کاوی در پزشکی و بررسی بیماری هپاتیت به وسیله الگوریتم وکا" پایان نامه کارشناسی ، دانشگاه پیام نور شهرکرد ، شهریور 1395

[5] عباس مدرکی ، خلاصه روش‌های داده کاوی

[6] ویکی پدیا ، الگوریتم آپریوری

[7] رضا صفدری ، مرجان قاسمی سعیدی ، منوچهر فارونی ، مهدی نصیری ، گلی ارجی "مقایسه عملکرد درخت تصمیم گیری و شبکه عصبی در پیشگویی ابتلا به آنفارکتوس قلبی" مجله علوم پزشکی و توانبخشی مشهد - دوره 3 - شماره 2 (پاییز و زمستان 1393)

[8] مریم سادات محمودی "طراحی سیستم پیشبینی بیماری قلبی- عروقی با استفاده از ماشین بردار پشتیبان." مجله انفورماتیک سلامت و زیست پزشکی

[9] سجاد مظاهری، مریم عاشوری ، زینب بچاری "پیش بینی روش درمان بیماری قلبی با استفاده از الگوریتم‌های داده کاوی" مجله دانشکده پیراپزشکی دانشگاه علوم پزشکی تهران - دوره 11 - شماره 3 - مرداد و شهریور 1396

[10] مریم کاظمی ، حسین مهدی زاده ، اردشیر شیر "پیش بینی بیماری قلبی با استفاده از تکنیک داده کاوی شبکه عصبی" مجله علمی دانشگاه علوم پزشکی ایلام - دوره بیست و پنج ، شماره اول اردیبهشت 96

[11] صباغ گل حامد تشخیص بیماری عروق کرونر قلبی با استفاده از درخت تصمیم C4.5. مجله انفورماتیک سلامت و زیست پزشکی. 1395: (4) 287-299

[12] آیت الهی هاله، غلامحسینی لیلا، صالحی مسعود. مقایسه عملکرد الگوریتم‌های داده‌کاوی در پیشبینی بیماری عروق کرونر. مجله انفورماتیک سلامت و زیست پزشکی 252-264: (2) 5



[13] D. Pelleg and A. Moore: "X-Means: Extending K-Means with Efficient Estimation of the number clusters", in: ICML '00 Proceedings of the Seventeenth International Conference on Machine Learning, pp 727-734, 2000.

[14] M.Rahimi , M.Bateni and H.Mohammadinejad “ Extended K-Anonymity Model for Privacy Preserving on Micro Data ” Published Online November 2015 in MECS

[15] کتاب داده کاوی کاربردی، دکتر محمد صنیعی آبادی، ۱۳۹۳